Trabajo 2 - Nombre grupo: van-go

Benjamín B.
20.165.296-0
benjamin.basauri@mail.udp.cl
kaggle user:benjamínb

Paolo E.
19.913.128-1
paolo.escobar@mail.udp.cl
kaggle user:PAOLO ANDRES ESCOBAR MUNOZ

Pedro O.
20.232.750-8
pedro.olivares1@mail.udp.cl
kaggle user: PEDRO OLIVARES1

Marcelo Y.
19.740.704-2
marcelo.araya1@mail.udp.cl
kaggle user: mrclynz

***Resumen*—Mediante el presente informe se detalla el proceso de construcción de una *Red Nuronal Densa* enfocada en la clasificacion de imagenes *Spambase*. en conjunto a esto se probo la configuracion de capas de una red neuronal por capas con relu, softmax y capas densas.**

***Index Terms*—DNN, Dense Layer, ReLu, SoftMax, Deep Learning**

I. Introducción

En la era de la información, las redes neuronales se han destacado en el manejo de grandes volúmenes de datos, especialmente en contextos de alta dimensionalidad, lo que presenta desafíos significativos como el sobreajuste y la dificultad en el manejo de estos datos sin una reducción de dimensionalidad efectiva. Las capas densas, en particular, juegan un rol crucial en muchas aplicaciones, aunque enfrentan limitaciones en escenarios complejos debido a estas dificultades.

Las técnicas de regularización y la ampliación de datos (data augmentation) han sido adaptativas en mejorar la generalización de los modelos, pero aún así, las redes neuronales necesitan nuevas aproximaciones para optimizar su desempeño. Un ejemplo es el uso de redes neuronales convolucionales (CNN) para la reconstrucción de espacios de fase de alta dimensionalidad, que ha mostrado ser eficaz sin necesidad de reducir la dimensionalidad, aprovechando la capacidad de las CNN para manejar directamente los datos de alta dimensionalidad.[1]

Además, los modelos basados en redes neuronales profundas han sido propuestos para estimar componentes de tendencia desconocidos en modelos espaciales de alta dimensión, considerando la dependencia y la heterogeneidad espacial. Estos modelos han demostrado tener una velocidad de convergencia significativamente mejor que los métodos locales lineales tradicionales, lo que indica una prometedora capacidad de adaptación y precisión en el manejo de datos espaciales complejos.[2]

Estos avances subrayan la importancia de continuar desarrollando y refinando técnicas que permitan a las arquitecturas de aprendizaje profundo abordar de manera más efectiva las limitaciones presentes en el análisis de grandes volúmenes de datos en múltiples disciplinas.

II. Redes neuronales

Las redes neuronales como concepto se inspiraron en la estructura y funcionamiento del cerebro humano, y el trabajo en este campo comenzó en serio en los años 1940s y 1950s con modelos como el perceptrón, creado por McCulloch y Pitts e implementado en hardware por primera vez por Frank Rosenblatt.

El perceptrón consiste en un algoritmo de clasificación binaria que utiliza una función de umbral para convertir una entrada x (un vector real) en una salida $f(x)$ (un valor binario):

$$f(x) = \phi(\theta^T x + \theta_0) \tag{1}$$

Donde ϕ es la función de activación, θ es la vector de entrada, x es el vector de pesos y θ_0 corresponde al sesgo.

Este modelo es bastante limitado, solo pudiendo resolver problemas linealmente separables. Por ejemplo, el modelo del perceptrón no puede resolver el problema de XOR.

Durante la década de 1980, el interés en las redes neuronales se revitalizó gracias a la introducción del algoritmo de retropropagación por Rumelhart, Hinton y Williams, que permitió entrenar redes de múltiples capas, conocidas como redes neuronales profundas. Este avance hizo posible aprender representaciones internas más ricas y complejas de los datos.

III. Capas y Funciones de Activación

Las capas en el contexto de las redes neuronales son estructuras fundamentales que organizan y facilitan el procesamiento de los datos en etapas. Cada capa puede considerarse como un nivel específico de transformación o procesamiento que los datos de entrada experimentan a medida que pasan a través de la red.

III-A. Capas Densas (Fully Connected Layers)

Las capas densas son esenciales en el ámbito de las redes neuronales por su capacidad de modelar cualquier función matemática, con un número adecuado de neuronas y capas ocultas, y son fundamentales en tareas de aprendizaje supervisado como la clasificación y la regresión. Esta capacidad se debe a su estructura, donde cada neurona en una capa está conectada

a todas las neuronas en la siguiente capa, lo que permite una rica interacción y transformación de características. [3], [4]

Además, la arquitectura de las redes densamente conectadas (DenseNet), donde cada capa se conecta a todas las siguientes, ofrece beneficios significativos como la mitigación de problemas de desvanecimiento de gradientes, la mejora en la propagación de características y la reutilización de las mismas, lo que las hace efectivas en tareas complejas como el procesamiento de imágenes y la regresión no lineal[5], [6]. Estas redes también han mostrado ser robustas en la clasificación de imágenes médicas y la identificación de espectros de Raman, demostrando su adaptabilidad y precisión en aplicaciones prácticas[7].

III-B. Función de Activación ReLU

La función Rectified Linear Unit está definida como:

$$ReLU(x) = \begin{cases} 0 & x \leq 0 \\ x & x > 0 \end{cases} \tag{2}$$

La función de activación Rectified Linear Unit (ReLU) se introdujo para ayudar a resolver el problema del gradiente desvaneciente que ocurre con funciones de activación saturadas como la sigmoid y tanh. La característica de no saturación de ReLU, donde solo se activa cuando las entradas son positivas, facilita el entrenamiento de modelos más profundos y más rápidos, siendo crucial para las arquitecturas modernas de aprendizaje profundo. ReLU permite una mayor eficiencia en el entrenamiento al permitir que los gradientes fluyan a través de la red sin el riesgo de desaparecer, lo cual es común con otras funciones como la sigmoid [8], [9], [10].

Este diseño de ReLU ayuda a mitigar significativamente los problemas de desvanecimiento del gradiente, especialmente en redes muy profundas, permitiendo que las redes neuronales aprendan más rápido y de manera más efectiva[6], [7]. Además, la simplicidad de la función ReLU, que simplemente pasa valores positivos y anula valores negativos, reduce la carga computacional, lo que la hace ideal para el procesamiento en tiempo real y aplicaciones que requieren una alta capacidad de respuesta[11].

III-C. Función Softmax

La función softmax es ampliamente utilizada en la última capa de las redes neuronales para tareas de clasificación multiclase. Esta función transforma las salidas lineales de la red de tal forma que se pueden interpretar como una distribución de probabilidad, donde cada valor de salida se encuentra entre 0 y 1, y la suma total de todas las salidas es exactamente 1. Esto es particularmente útil para problemas de clasificación multiclase, ya que cada salida representa la probabilidad de que la entrada pertenezca a una clase en particular[12], [13], [14].

La función softmax está dada por:

$$\sigma(x)_j = \frac{e^{x_j}}{\sum_{k=1}^{K} e^{x_k}} \tag{3}$$

Esta característica de la función softmax la hace ideal para aplicaciones en las que es necesario determinar claramente la categoría a la que pertenece una entrada, como en el reconocimiento de imágenes o en la clasificación de texto, donde se necesita una salida clara y diferenciada para cada categoría posible.

IV. Metodología y Experimentos

IV-1. Análisis de datos:

- **Limpieza de Datos** Para preparar los datos a usar, se lleva a cabo una revisión preliminar del conjunto de datos de entrenamiento para verificar la presencia de valores nulos.
- **Verificación de Datos** Tras una revisión, se valida que el conjunto de datos no posee valores nulos.

IV-2. Desarrollo de experimentos:

- **Normalización de los datos:** Se opta por el escalado debido a su capacidad para transformar los datos a un rango uniforme, lo que reduce la dominancia de ciertas variables sobre otras y mejora la convergencia del modelo. [15]
- **Capas de aplanamiento:** Para reducir la dimensionalidad de los datos se utiliza una capa de aplanamiento (flatten layer), dejando los datos listos para realizar el entrenamiento.
- **Capas densas:** Dentro del modelo se hace uso de capas densas para conectar las capas con el objetivo de cambiar las dimensiones con las que entran los vectores.
- **Capas ReLU:** Como función de activación se decidió utilizar ReLU por su gran rendimiento (tanto en profundidad como en velocidad). En total se utilizan cuatro capas ReLU para mejorar su capacidad de aprender.
- **Capas Softmax:** Se utiliza la función Softmax como la función de clasificación en el entrenamiento del modelo para así poder posteriormente medir la perdida por entropía cruzada.
- **Perdida de entropía cruzada:** Debido a que se tiene un problema de clasificación, se utiliza la perdida de entropía cruzada como función de perdida.
- **Inicialización:** Se elige utilizar el método de inicialización de He debido a que este considera particularmente las características de la función ReLU, con el fin de evitar el problema de vanishing gradients o exploding gradients[16].
- **Parámetros:** Los parámetros en uso fueron escogidos por dar los mejores resultados después de una serie de intentos con diferentes valores.
- **Validación cruzada k-fold:** Para evaluar el rendimiento de nuestro modelo se realiza una validación cruzada k-fold.

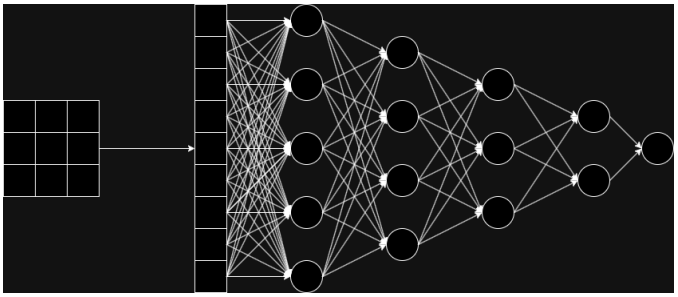

Figura 1. Arquitectura del modelo.

IV-A. Resultados

Se exponen los resultados obtenidos:

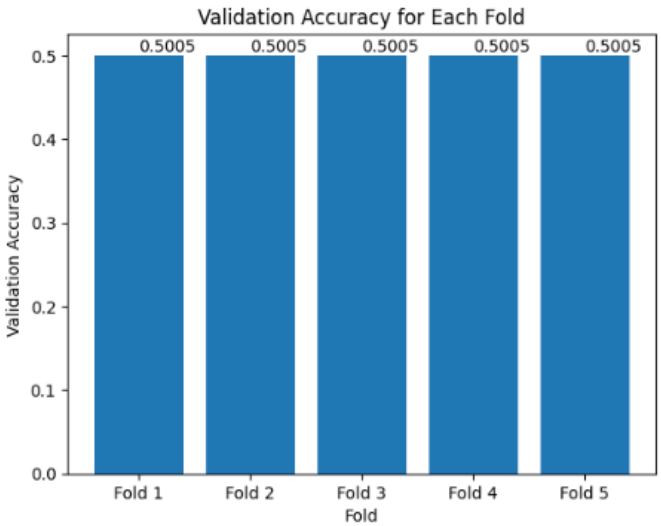

Figura 2. Gráfico de precisión (validation accuaracy) por cada pliegue (fold) del proceso de validación cruzada k-fold.

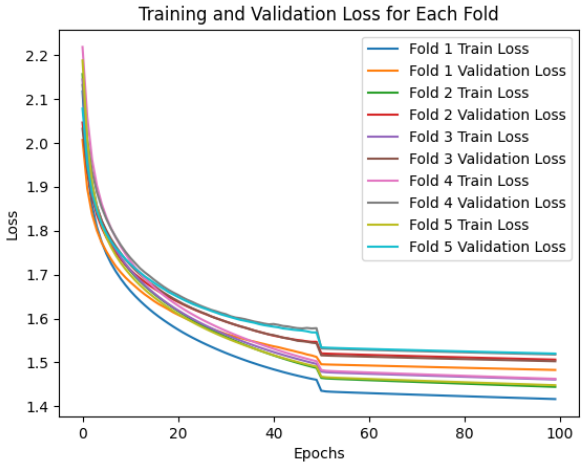

Figura 3. Gráfico de perdidas (loss) vs iteraciones (epochs) para los 5 folds.

V. Conclusiones

En el transcurso de esta investigación, se examinó la efectividad de una red neuronal profunda (DNN) basada en conexiones de capas densas y funciones de activación ReLU y Softmax. A través de este estudio, se confirmó la capacidad de las DNN para procesar y aprender de grandes volúmenes de datos. No obstante, se evidenció que, en comparación con arquitecturas más modernas como las redes convolucionales (CNN), las DNN presentan ciertas desventajas en términos de eficiencia y precisión, especialmente en tareas relacionadas con el procesamiento y la generación de imágenes[12], [13]..

Este fenómeno se puede atribuir a la estructura intrínseca de las DNN, que aunque fue pionera en los primeros enfoques de modelado de imágenes, carece de la capacidad de captar la localidad y la jerarquía espacial en las imágenes, aspectos que son manejados de manera más eficiente por las CNN. Las CNN, al incorporar filtros convolucionales, están específicamente diseñadas para aprovechar estas características espaciales, lo que resulta en una mejor interpretación de los datos visuales[14].

Por lo tanto, aunque las DNN siguen siendo una herramienta valiosa en el campo del aprendizaje profundo, su aplicación podría considerarse menos óptima para tareas que requieren un alto grado de reconocimiento visual y análisis detallado de las características espaciales, áreas en las cuales las CNN demuestran un desempeño superior.

Referencias

[1] Y.-L. C. et all, "High-dimensional phase space reconstruction with a convolutional neural network for structural health monitoring," 2021.
[2] H. W. et all, "Nonparametric estimation for high-dimensional space models based on a deep neural network," 2023.
[3] F. M. et all, "An efficient optimization technique for training deep neural networks," 2023.
[4] G. D. C. et all, "Exploring neural network hidden layer activity using vector fields," 2020.
[5] W. Z. et all, "Dense convolutional neural network for identification of raman spectra," 2023.
[6] C. J. et all, "Densely connected neural networks for nonlinear regression," 2022.
[7] O. Özkaraca et all, "Multiple brain tumor classification with dense cnn architecture using brain mri images," 2023.
[8] Z. B. et all, "Joint gravity and magnetic inversion using cnns' deep learning," 2024.
[9] A. P. et all, "Sinlu: Sinu-sigmoidal linear unit," 2022.
[10] G. M. et all, "Nipuna: A novel optimizer activation function for deep neural networks," 2023.
[11] K. S. et all, "Improved u-net: Fully convolutional network model for skin-lesion segmentation," 2020.
[12] A. A. Y. et all, "A novel handwritten digit classification system based on convolutional neural network approach," 2021.
[13] H. Z. et all, "A deep convolutional neural network-based multi-class image classification for automatic wafer map failure recognition in semiconductor manufacturing," 2021.
[14] H. K. et all, "Sentiment classification using convolutional neural networks," 2019.
[15] Md Manjurul Ahsan et al., "Effect of Data Scaling Methods on Machine Learning Algorithms and Model Performance," 2021.
[16] K. He, X. Zhang, S. Ren, and J. Sun, "Delving deep into rectifiers: Surpassing human-level performance on imagenet classification," 2015.